


基于隐马尔可夫链（HMM）的 金融市场交易策略设计

蔡玮钦 516120910098

王奕能 516120910101

王振宇 5141619041

背景介绍



- Renaissance & Medallion（文艺复兴科技和大奖章）
- 由Simons带领一群物理学家和数学家碰撞在一起
- 1989年到2008年的年化收益达到35.6%。在全球金融危机的08年，大部分对冲基金都亏损，而大奖章的return高达80%。
- 成立初期的创始人中，鲍姆等人提出了广泛应用在语音识别等领域的HMM模型和鲍姆-威尔士算法，用来确定不可确知的变量可能出现的概率。
- 人大的一位教授14年也写了一本书——解密复兴科技：基于隐蔽马尔科夫模型的时序分析方法。

原理部分

隐马尔可夫模型

确定模型参数

确定最佳历史隐状态序列

- 隐马尔可夫模型
 - 基本假设
 - 决定参数
- 确定模型参数
 - Baum-Welch算法
- 确定最佳历史隐状态序列
 - Viterbi算法

隐马尔可夫模型

- 定义：
 - $\{X_n\}$ 是一个普通的马尔可夫链, 每当马尔可夫链进入状态 j 时, 以概率 $p(s|j)$ 给出信号 s , 用 $\{S_n\}$ 表示信号序列, 如果隐状态 X_n 不可观测, 而信号 S_n 可以被观测, 则得到一个隐马尔可夫模型。
- 基本假设：
 - X_n 仅和 X_{n-1} 有关, 即 $P(X_n|S_n, X_{n-1}, S_{n-1}, \dots, X_1, S_1) = P(X_n|X_{n-1})$
 - S_n 仅和 X_n 有关, 即 $P(S_n|X_n, S_{n-1}, X_{n-1}, \dots, S_1, X_1) = P(S_n|X_n)$

隐马尔可夫模型

- 参数:

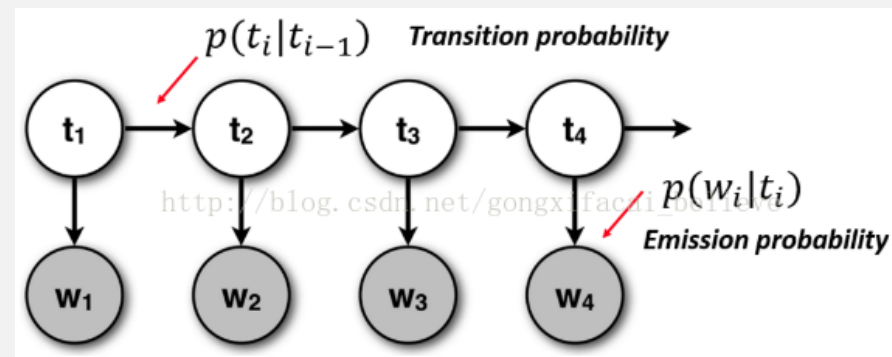
- $\{X_n\}$ 的初始状态概率分布 π

初始状态概率分布	状态 1	状态 2	状态 n
概率	π_1	π_2	π_n

- $\{X_n\}$ 的转移矩阵 A 和模型的观测矩阵 B

$$\begin{pmatrix} \alpha_{11} & \alpha_{12} & \dots & \alpha_{n1} \\ \alpha_{21} & \alpha_{22} & \dots & \alpha_{n2} \\ \dots & \dots & \dots & \dots \\ \alpha_{n1} & \alpha_{n2} & \dots & \alpha_{nn} \end{pmatrix}$$

$$\begin{pmatrix} \beta_{11} & \beta_{12} & \dots & \beta_{n1} \\ \beta_{21} & \beta_{22} & \dots & \beta_{n2} \\ \dots & \dots & \dots & \dots \\ \beta_{n1} & \beta_{n2} & \dots & \beta_{nn} \end{pmatrix}$$



α_{ij} 表示状态 i 转移到状态 j 的概率

β_{ij} 表示不可观测的状态处在 i 时给出可观测信号 j 的概率

确定模型参数

- 假设股票/期货市场存在着某些不可观测的隐状态，这些状态满足马尔可夫链构成 $\{X_n\}$ 。每天可观测到的价格走势作为状态的信号 $\{S_n\}$ 。
- 该模型中，初始概率分布 π ，转移矩阵 A ，观测矩阵 B 都未知，仅可观测到信号。需要估计参数 $\lambda(\pi, A, B)$ 。


确定模型参数

- Baum-Welch 算法：
 - 估计 λ 并使 $P(\{S_n\}|\lambda)$ 最大，采用对数极大似然估计。
 - $\bar{\lambda}$ 为当前估计参数,计算机循环迭代得到使 Q 最大的 λ ，即最佳估计参数。

$$Q(\bar{\lambda}, \lambda) = \sum_{\{X_n\}} (\ln(P(\{X_n\}, \{S_n\}|\lambda))) P(\{X_n\}|\{S_n\}, \bar{\lambda})$$

VITERBI算法

- 最大化状态路径的概率：
 - $\text{Max}(P(X_n, X_{n-1}, \dots, X_1 | \lambda, S_n, S_{n-1}, \dots, S_1))$
- 1初始化, 对每个i
 - $t=1$ 时, $\delta_{s_1}(i) = \pi_i \beta_{js_1}$
- 2递推($k > 1$), 对每个i,j
 - $t=k$ 时, $\delta_{s_k}(i) = \max(\delta_{s_{k-1}}(j) \alpha_{ji} \beta_{is_k})$
对j取max
- 3终点
 - 取最大的 $\delta_{s_n}(i)$
- 4逆向找 i_n



$\delta_{s_k}(i)$ 表示第k步观测到 S_k 且处在状态i的最大路径概率

ETF实证部分

数据来源

交易策略

策略表现

- 基于前述的模型，我们构建了相应的交易策略。
- 其中，在ETF上的应用不算成功，但在期货价差上能有较好表现。主要在价差部分介绍具体策略。

变量定义

50ETF (510050) 2010-2019年数据



变量名	定义
open, high, low, close	开/高/低/收盘价
ret1	$\text{close}_t / \text{close}_{t-1} - 1$
ret5	$\text{close}_t / \text{close}_{t-5} - 1$
ATR	Average True Range
RSI	Relative Strength Index
OBV	On Balance Volume
MFI	Money Flow Index

$$ATR(n)_t = \frac{1}{n} \sum_{i=1}^n TR_{t-i+1}$$

Source: Wind



样本内标注

- 首先对数据进行样本内标注，查看各个隐状态之间是否有区分度
- 取隐状态个数=6
- 例如：
 - Hidden state 0: 震荡
 - Hidden state 2: 熊市
 - Hidden state 3: 牛市
 - Hidden state 4: 熊市



样本外标注

- 样本外数据看似良好地延续了隐状态对应样本内的特征
- 例如:
 - Hidden state 3: 牛市
 - Hidden state 4: 熊市
- 将两者一对冲就可以用来交易? No



遇到的问题

- 尽管样本外各种隐状态有区分度，但实际交易中不可能预知未来的可观测序列。
- 因此，上述方法至多是一个伪回测
 - 中信期货《隐马尔可夫模型商品期货应用初探》一文很睿智地使用了上述方法。
 - 尝试使用[其他策略](#)但效果不佳

期货实证部分

数据来源

交易策略

回测表现


- 实证中我们发现股票类价格序列不平稳：
 - 其统计特征不易于延续
 - 隐马尔科夫模型相当依赖于统计特征
- 转而寻找较为平稳的时间序列：
 - 例如 高相关性期货品种价差序列
- 商品期货价差序列数据维度较小：
 - 一阶矩很容易获得
 - 但不存在直接的交易量等数据

数据来源



- 选择豆一和豆粕两个相关系数较高的品种（近一年两者相关系数0.802）

豆一和豆粕合约价格走势图（日频，2005/01 - 2019/03）





- 以上数据均来自Wind数据库

变量定义

变量名	定义
close	豆粕close - 豆一close
ret1	$\text{close}_t / \text{close}_{t-1} - 1$
ret5	$\text{close}_t / \text{close}_{t-5} - 1$
ret10	$\text{close}_t / \text{close}_{t-10} - 1$
ret20	$\text{close}_t / \text{close}_{t-20} - 1$

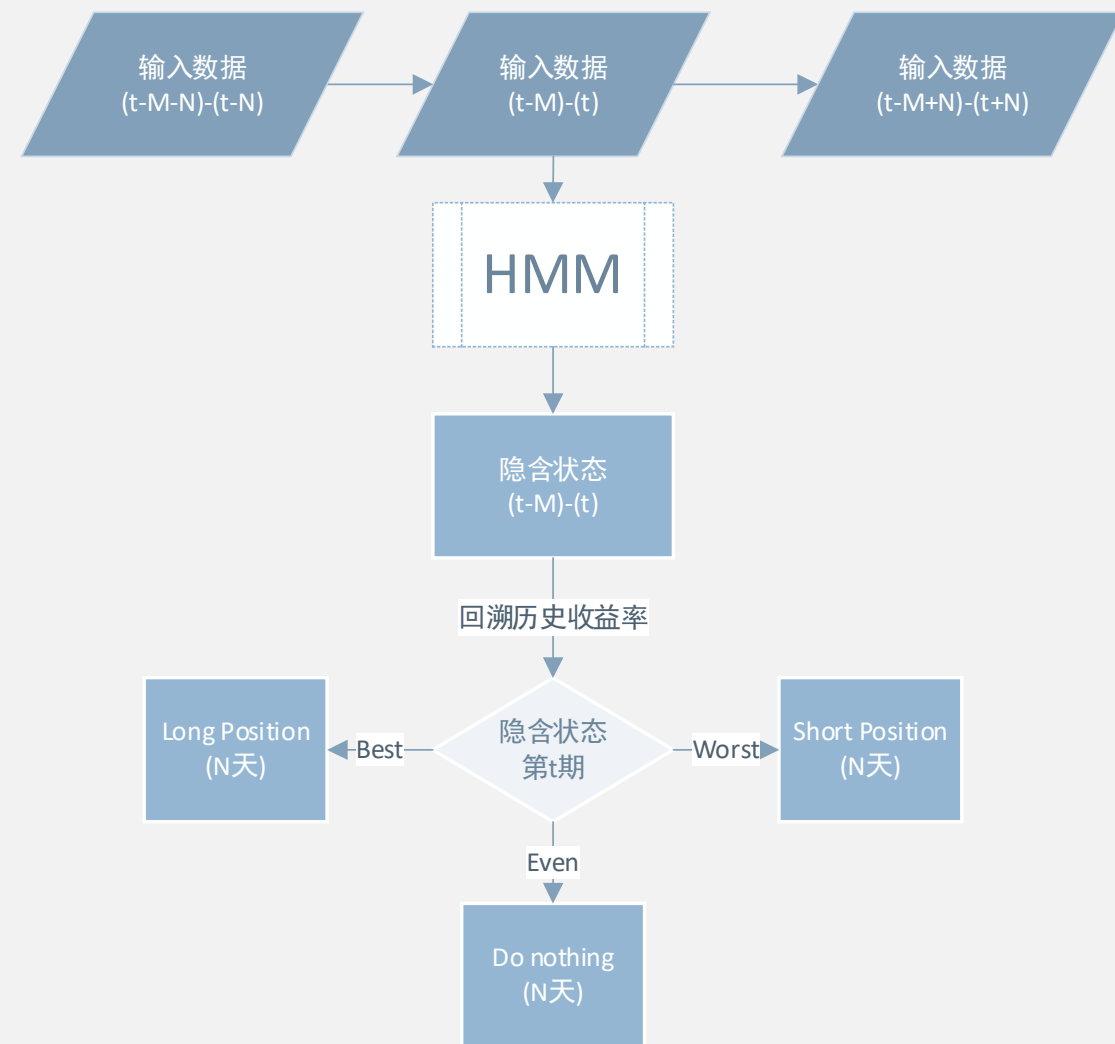
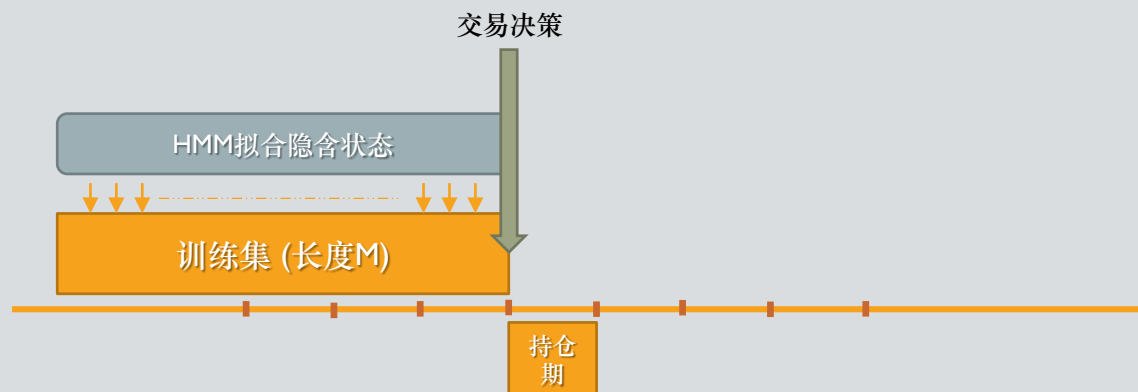
数据初探

- 首先对数据进行样本内标注，查看各个隐状态之间是否有区分度
- 利用 $ret1, ret5, ret10$ 作为观测值对隐状态标记的结果较好



交易策略

- 策略滚动回测流程图示意图



交易策略

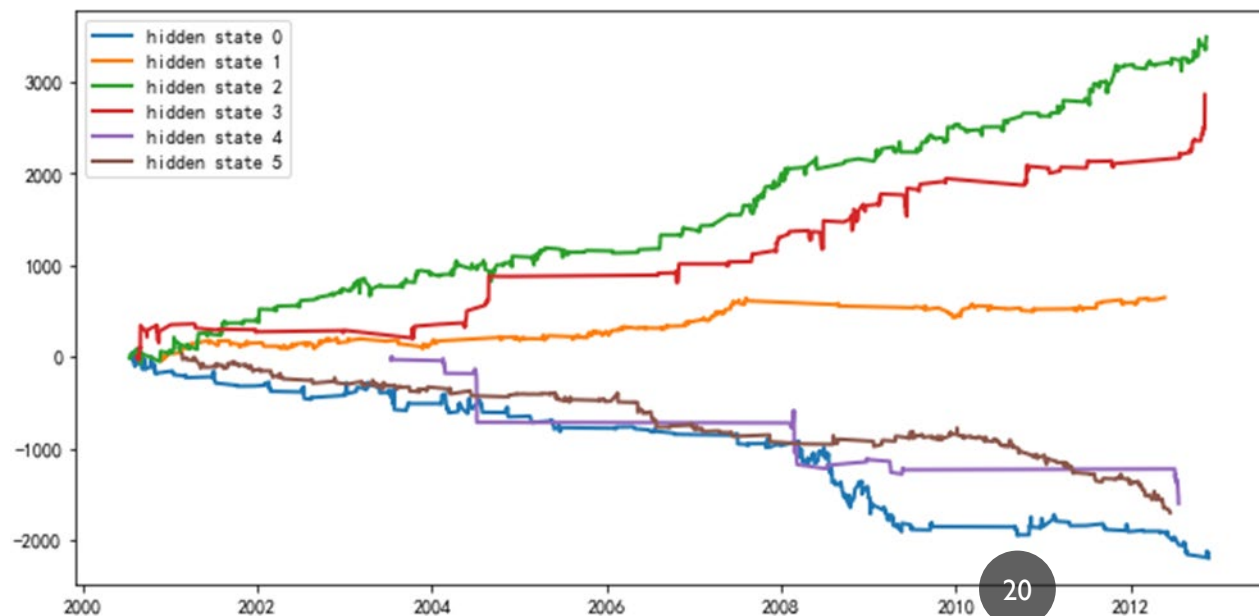

- 采用滚动回测方式：使用过去M天的观测值序列进行参数估计，用最后一天的隐含状态来预测后N天的状态。
- 一个典型的 Embedded Markov Transition Matrix 如下。可以看到下一阶段转移到别处的概率都较小，留在原处的概率最大。

	0	1	2	3	4	5
0	0.676906	0.14084	0.0159308	0.069996	0.00202478	0.094302
1	0.156863	0.599827	0.00189536	0.0403659	0.0237836	0.177265
2	0.0203786	0.0436632	0.719506	0.197854	8.60321e-17	0.0185988
3	0.180515	0.023688	2.9031e-06	0.750891	0.0397787	0.00512427
4	0.0251405	0.0254936	0.00777064	0.0297438	0.783649	0.128203
5	0.0264203	0.221896	0.0096795	0.0122587	0.0796568	0.650088

- 因此，根据状态转移矩阵预测到的下一期隐状态即为当期隐状态。

交易策略


- 隐状态对应含义不确定，且起始状态也不确定，无法直接判断在各个隐状态下应该如何交易。
- 需要借助样本内各个隐状态对应的收益来判断交易策略。
- 例如，右图中程序可以自动判断在 *hidden state 2* 应当做多，在 *hidden state 0* 应当做空。
- 选取2013-2019年的数据做回测
- 交易频率较低，手续费可以忽略不计




策略表现

2013-2019年 M=2000 N=5


ret1, ret5



★ ret1, ret5, ret10




ret1, ret5, ret10, ret20



策略表现

2013-2019年 M=2000 N=5



	ret5	ret10	ret20
总收益	9.42%	30.72%	15.40%
胜率	47.65%	55.46%	57.50%
最大回撤	-14.39%	-6.03%	-8.75%
夏普比率	0.31	0.91	0.47

总结与展望

具有稳定的收益

可以用于交易

模型解释能力不足

- 实证结果表明HMM模型可以被应用于交易策略的设计
 - 具有较稳定的收益
 - 独创性地应用于商品价差
- 但模型仍存在一些不足：
 - 属于机器学习一类的模型
 - 模型解释力不足
 - 需要非常大量的训练数据

总结与展望

更多品种的金融资产

配合期权策略

利用时间序列模型

- 由于时间有限，我们的模型还有很多有待拓展的地方：
 - 配合期权交易策略：

有些隐状态对应于市场震荡，此时卖出Strangle/Straddle期权组合会有效提高收益和资金利用率
 - 配合时间序列模型：

事实上用GARCH一类的模型来预测平稳的时间序列很有优势，可以用多个隐状态同时构建多个GARCH，依据隐状态来选择时间序列模型。

总结与展望

输入数据的处理

交易策略

- 由于时间有限，我们的模型还有很多有待拓展的地方：
 - 输入数据：
 - 可以加入机构持仓量
 - 遇到高维数据可以采用PCA方法降维
 - 交易策略上：
 - 尝试更多频率
 - 尝试止损止盈

THANKS

Q&A

APPENDIX

另一种交易策略方法

- 利用确定的模型参数 (π, A, B) , 和窗口的观测信号 $\{S_n\}$, 求窗口后一天的信号的分布。
- 直接根据估计的信号制定交易策略。
 - 如估计下一天的信号为上涨[3%,5%], 买入股票。

另一种交易策略方法（续）

- 前向概率： $F_n(j) = P(S^n = s^n, X_j)$

S^n 表示前 n 个信号的随机向量， s^n 表示某个信号向量。

$F_n(j)$ 可以由以下递推得到：

$$F_1(j) = \pi_j \beta_{js_1}, F_n(j) = \beta_{js_n} \sum_i F_{n-1}(i) \alpha_{ij}$$

- 窗口最后一天的隐状态概率分布：

$$P(X_n = j | S^n = s_n) = \frac{P(X_n = j, S^n = s_n)}{P(X_n = j)} = \frac{F_n(j)}{\sum_i F_n(i)}$$

- 预测第 $n+1$ 天的隐状态分布，取条件于 X_n

$$P(X_{n+1} = j | s^n) = \sum_i \alpha_{ij} P(X_n = i | s^n)$$

- 预测第 $n+1$ 天的收益率分布，取条件于 X_{n+1}

- $P(S_{n+1} = j | s^n) = \sum_i \beta_{ij} P(X_{n+1} = i)$


参数敏感性测试 – 总收益率

多最好的一个隐状态，空最差的一个隐状态

	M=1000	M=2000	M=3000
N=1	7.36%	5.76%	-4.68%
N=5	0.00%	30.72%	21.56%

多最好的两个隐状态，空最差的一个隐状态

	M=1000	M=2000	M=3000
N=1	1.76%	13.55%	8.39%
N=5	-9.89%	21.79%	-18.25%



HMM程序

选取全样本前半部分作为训练集，后半部分作为测试集

对于可观测序列进行隐马尔科夫链建模

```
trainX = A[:3000]
```

```
testX = A[3000:]
```


```
model = GMMHMM(n_components=6, n_iter=2000).fit(trainX)
```

```
hidden_states = model.predict(testX)
```

状态标注作图程序

```
### ax0: 样本内的隐状态标注, ax1: 样本内各个隐状态对应的收益曲线
_, axes = plt.subplots(2, 1, figsize=(11, 12))
for i in range(model.n_components):
    pos = (hidden_states==i)
    axes[0].plot(data.iloc[pos]['close'], 'o', label='hidden state %d'%i, lw=2)
    axes[1].plot(data['ret1'].shift(-1).iloc[pos].apply(np.exp).cumprod(),
                  label='hidden state %d'%i, lw=2) # 复合收益率
axes[0].legend(); axes[1].legend() # 添加图例
```


ETF实证部分 - 滚动回测



- 将期货实证部分的策略运用于ETF序列上，发现HMM模型完全没有头绪地在进行交易。
- 我们将其归因为数据不平稳。

遇到的问题

- 尽管样本外各种隐状态有区分度，但实际交易中不可能预知未来的可预测序列。
- 因此，上述方法至多是一个伪回测
- 中德期货《隐马尔可夫模型商品期货应用初探》一文很睿智地使用了上述方法。
- 尝试使用[其他模型](#)但效果不佳

隐马尔可夫链 (HMM)

参考文献

- S. Ross, *Introduction to Probability Models*
- 朱民 等, *解密复兴科技: 基于隐蔽马尔科夫模型的时序分析方法*。
- 中信期货, *隐马尔可夫模型商品期货应用初探*
- 兴业证券, *股指期货交易策略系列报告之三: 基于隐马尔科夫链的交易策略*
- 唐灵儿, *基于HMM-GARCH 模型的期权定价研究*
- Lawrence R. Rabiner “A tutorial on hidden Markov models and selected applications in speech recognition”, *Proceedings of the IEEE* 77.2, pp. 257-286, 1989.
- Jeff A. Bilmes, “A gentle tutorial of the EM algorithm and its application to parameter estimation for Gaussian mixture and hidden Markov models.”, 1998.

成员分工

- 蔡玮钦、王振宇
 - HMM模型部分（数学原理和算法）
- 王奕能
 - 实证部分（程序和回测）